

# Introdução a Inteligência Artificial

---

# Introdução

Inteligência Artificial (IA) é um campo da ciência da computação que se dedica a criar sistemas capazes de realizar tarefas que normalmente exigiriam inteligência humana. Esses sistemas podem processar grandes volumes de dados, reconhecer padrões, aprender com experiências anteriores e tomar decisões baseadas em informações complexas.

Existem dois tipos principais de IA: a IA fraca e a IA forte. A IA fraca é projetada para realizar tarefas específicas, como assistentes virtuais (Siri, Alexa) e sistemas de recomendação (Netflix, Spotify). Já a IA forte busca replicar a capacidade cognitiva humana de forma mais abrangente, o que inclui a habilidade de raciocinar, planejar e resolver problemas de maneira geral.

# Introdução

Os principais subcampos da IA incluem aprendizado de máquina (machine learning), onde sistemas são treinados para melhorar seu desempenho com base em dados; processamento de linguagem natural (NLP), que permite a compreensão e geração de linguagem humana; e visão computacional, que envolve o reconhecimento e interpretação de imagens e vídeos.

IA tem aplicações em diversas áreas, como saúde, finanças, transporte e entretenimento, oferecendo soluções inovadoras e eficientes. No entanto, também levanta questões éticas e desafios, como o impacto no mercado de trabalho e a privacidade dos dados.

# Introdução

Em resumo, a IA está transformando a forma como vivemos e trabalhamos, trazendo tanto oportunidades quanto desafios, e seu desenvolvimento contínuo promete ainda mais avanços e mudanças no futuro.

# Tipos de IA

Tipos de IA:

- IA Estreita: Faz uma tarefa específica (ex: assistentes virtuais).
- IA Geral: Inteligência em nível humano (não existe ainda).
- IA Forte: Capaz de raciocinar, resolver problemas e tomar decisões de forma independente.

# IA Estreita (Narrow AI)

Definição: Projetada para realizar uma tarefa específica ou um conjunto limitado de tarefas.

Requisitos:

1. Algoritmos Específicos: Algoritmos otimizados para a tarefa específica (e.g. (exemplo), reconhecimento de voz, recomendação de produtos).
2. Treinamento Supervisionado: Grande quantidade de dados rotulados para treinar modelos.
3. Processamento de Dados: Capacidade de processar e analisar grandes volumes de dados rapidamente.
4. Infraestrutura de TI: Hardware adequado para o treinamento e execução de modelos (e.g., GPUs(Unidade de processamento gráfico)).
5. Atualizações e Manutenção: Sistema de atualização contínua para melhorar a precisão e eficácia do modelo.

# IA Geral

Definição: Inteligência artificial que possui a capacidade de entender, aprender e aplicar conhecimentos de forma abrangente, similar a um ser humano.

Requisitos:

1. Versatilidade Cognitiva: Capacidade de aprender e executar uma ampla gama de tarefas sem necessidade de reprogramação.
2. Compreensão Contextual: Entendimento profundo de contextos variados para aplicar conhecimentos em diferentes situações.
3. Adaptabilidade: Capacidade de se adaptar e aprender com novas situações e informações.
4. Raciocínio Abstrato: Habilidade de raciocinar de forma abstrata e solucionar problemas complexos.
5. Memória e Aprendizado Contínuo: Sistemas que permitem armazenamento de longo prazo e aprendizado contínuo a partir de novas experiências.

# Introdução a Machine Learning

- O que é: Machine Learning (ML) é uma subárea da IA que ensina máquinas a aprenderem a partir de dados.
- Tipos de aprendizado:
- Supervisionado: A máquina aprende com dados rotulados (ex: e-mails marcados como spam ou não).
- Não supervisionado: A máquina encontra padrões em dados não rotulados (ex: agrupamento de clientes).
- Por reforço: A máquina aprende por tentativa e erro, recebendo recompensas ou punições.



# Fluxo de Trabalho em Machine Learning

- Etapas para criar uma IA
- Coleta de dados: Reunir os dados necessários para treinar a IA.
- Pré-processamento dos dados: Limpar e preparar os dados para análise.
- Escolha do modelo: Selecionar o tipo de modelo de ML a ser usado.
- Treinamento do modelo: Ensinar o modelo usando os dados.
- Avaliação do modelo: Verificar a precisão e a eficiência do modelo.
- Implantação do modelo: Colocar o modelo em uso no mundo real.
- Manutenção: Continuar ajustando e melhorando o modelo ao longo do tempo.

# Escolha do Modelo

- Tipos de modelos de Machine Learning
- Modelos lineares: Regressão linear (previsão), regressão logística (classificação).
- Modelos de árvore de decisão: Árvores de decisão (divisão de dados em grupos), floresta aleatória (múltiplas árvores).
- Modelos de rede neural: Perceptron multicamadas (múltiplas camadas de neurônios), redes neurais convolucionais (análise de imagens), redes neurais recorrentes (análise de sequências).

# Treinamento do Modelo

- Divisão dos dados
- Treino: Dados usados para ensinar o modelo.
- Validação: Dados usados para ajustar o modelo.
- Teste: Dados usados para avaliar a performance final do modelo.
- Algoritmos de otimização
- Gradiente descendente: Método para ajustar os pesos do modelo.
- Ajuste de hiperparâmetros: Escolher os melhores parâmetros para o modelo.

# Avaliação do modelo

- Métricas de performance
- Acurácia: Percentual de previsões corretas.
- Precisão e recall: Medidas para avaliar a qualidade das previsões (importante em casos de classes desbalanceadas).
- F1-score: Combinação de precisão e recall.
- Matriz de confusão: Tabela que mostra previsões corretas e incorretas.
- Curvas ROC e AUC: Gráficos para avaliar a performance de modelos de classificação.

Mas vamos descomplicar cada um desses tópicos!

# Avaliação do modelo

- 1. Acurácia
- Definição: A acurácia é a proporção de previsões corretas em relação ao total de previsões feitas.
- Exemplo: Se um modelo fez 100 previsões e acertou 90 delas, a acurácia é 90%.
- Uso: É uma métrica útil quando as classes estão balanceadas, ou seja, há uma quantidade semelhante de exemplos de cada classe.

# Avaliação do modelo

- 2. Precisão e Recall
- Precisão (Precision): Definição: A precisão é a proporção de previsões positivas corretas em relação ao total de previsões positivas feitas.
- Exemplo: Se um modelo previu que 10 emails são spam e 7 deles realmente são spam, a precisão é 70%.
- Uso: Importante quando o custo de um falso positivo é alto (ex.: em diagnósticos médicos).

# Avaliação do modelo

- Recall (Sensibilidade): Definição: O recall é a proporção de previsões positivas corretas em relação ao total de casos positivos reais.
- Exemplo: Se há 10 emails de spam e o modelo identificou corretamente 7 deles, o recall é 70%.
- Uso: Importante quando o custo de um falso negativo é alto (ex.: na detecção de fraudes).

# Avaliação do modelo

- Definição: O F1-score é a média harmônica entre precisão e recall. Ele equilibra os dois valores, sendo útil quando se quer considerar ambos os aspectos.

**Fórmula:**

$$\text{F1-score} = 2 \times \frac{\text{Precisão} \times \text{Recall}}{\text{Precisão} + \text{Recall}}$$

- Exemplo: Se a precisão e o recall são ambos 70%, o F1-score também será 70%.
- Uso: Útil quando as classes estão desbalanceadas e é necessário considerar tanto falsos positivos quanto falsos negativos.



# Avaliação do modelo

- Definição: Uma tabela que mostra a distribuição das previsões corretas e incorretas do modelo.
- Estrutura:
- Verdadeiro Positivo (TP): Previsões corretas de classe positiva.
- Falso Positivo (FP): Previsões incorretas de classe positiva.
- Verdadeiro Negativo (TN): Previsões corretas de classe negativa.
- Falso Negativo (FN): Previsões incorretas de classe negativa.

	Predito Positivo	Predito Negativo
Real Positivo	TP	FN
Real Negativo	FP	TN

# Avaliação do modelo

- Curva ROC (Receiver Operating Characteristic): Definição: Um gráfico que mostra a performance de um modelo de classificação em diferentes limiares de decisão.
- Eixos:
- Eixo Y (True Positive Rate): Taxa de verdadeiros positivos (recall).
- Eixo X (False Positive Rate): Taxa de falsos positivos ( $1 - \text{especificidade}$ ).
- Exemplo: Uma curva ROC próxima do canto superior esquerdo indica um bom desempenho.
- Uso: Avalia a capacidade de discriminação do modelo.

# Avaliação do modelo

- AUC (Area Under the Curve): Definição: A área sob a curva ROC. Varia de 0 a 1, onde 1 representa um modelo perfeito e 0.5 um modelo aleatório.
- Exemplo: Um AUC de 0.9 indica que o modelo tem uma boa capacidade de separação entre as classes.
- Uso: Fornece um único valor para avaliar a performance geral do modelo.

# Implantação do modelo

- Formas de implantar um modelo
- APIs: Interfaces de programação que permitem que outros sistemas usem o modelo.
- Aplicações web e móveis: Incorporar o modelo em aplicativos usados por usuários finais.
- Dispositivos embarcados: Usar o modelo em dispositivos como sensores e câmeras.

# Manutenção e monitoramento

- Importância da manutenção
- Monitoramento: Acompanhar a performance do modelo em uso.
- Atualização: Treinar o modelo novamente com novos dados.
- Drift de dados: Mudanças nos dados que podem afetar a performance do modelo.

**Hora da Prática!**

**Você acredita que a IA um dia poderá ser totalmente independente do ser humano?**

# Passo a passo da dinâmica

- Montem equipes
- Definição das categorias (animais, frutas, veículos, cores).
- Escolha das imagens – Escolha as imagens de treino e as imagens de teste.
- Confecção dos cartões de categoria (papel e caneta).

As imagens serão mostradas e cada grupo vai adicioná-la a uma categoria (levantar os cartões), e criar uma frase que descreva totalmente a imagem!

E depois começa a surpresa!